

```
In [1]: import pandas as pd  
import matplotlib.pyplot as plt  
import seaborn as sns
```

- Importando e entendendo base de dados

```
In [2]: #Ler arquivo CSV  
df = pd.read_csv(r"data\student_habits_performance.csv")
```

```
In [3]: #Visualizar dados  
df
```

```
Out[3]:   student_id  age  gender  study_hours_per_day  social_media_hours  netflix_hours  ...  
          0        S1000  23  Female           0.0              1.2            1.1  
          1        S1001  20  Female           6.9              2.8            2.3  
          2        S1002  21    Male           1.4              3.1            1.3  
          3        S1003  23  Female           1.0              3.9            1.0  
          4        S1004  19  Female           5.0              4.4            0.5  
         ...        ...  ...    ...           ...              ...            ...  
         995       S1995  21  Female           2.6              0.5            1.6  
         996       S1996  17  Female           2.9              1.0            2.4  
         997       S1997  20    Male           3.0              2.6            1.3  
         998       S1998  24    Male           5.4              4.1            1.1  
         999       S1999  19  Female           4.3              2.9            1.9
```

1000 rows × 16 columns




- Quais hábitos impactam mais o desempenho dos alunos?

```
In [4]: #Tipos de dados  
  
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 16 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   student_id      1000 non-null    object  
 1   age              1000 non-null    int64  
 2   gender           1000 non-null    object  
 3   study_hours_per_day  1000 non-null  float64 
 4   social_media_hours 1000 non-null  float64 
 5   netflix_hours    1000 non-null    float64 
 6   part_time_job    1000 non-null    object  
 7   attendance_percentage 1000 non-null  float64 
 8   sleep_hours      1000 non-null    float64 
 9   diet_quality     1000 non-null    object  
 10  exercise_frequency 1000 non-null  int64  
 11  parental_education_level 909 non-null  object  
 12  internet_quality 1000 non-null    object  
 13  mental_health_rating 1000 non-null  int64  
 14  extracurricular_participation 1000 non-null  object  
 15  exam_score       1000 non-null    float64 
dtypes: float64(6), int64(3), object(7)
memory usage: 125.1+ KB
```

```
In [5]: #Colunas numéricas
cols = [
    "study_hours_per_day",
    "social_media_hours",
    "netflix_hours",
    "sleep_hours",
    "attendance_percentage",
    "exercise_frequency",
    "mental_health_rating",
    "exam_score",
]


# Plotar mapa de calor (heatmap)
sns.heatmap(df[cols].corr(), annot=True, cmap="coolwarm")
plt.title("Correlação entre hábitos e nota final")
plt.show()
```



- Alunos que estudam mais tem melhor desempenho?

```
In [6]: # Gráfico de dispersao com Linha de regressao
# x="study_hours_per_day" / y="exam_score"
sns.lmplot(data=df, x="study_hours_per_day", y="exam_score")
plt.title("Mais estudo -> notas mais altas?")
plt.show()
```

Mais estudo -> notas mais altas?



```
In [7]: #Comparado médias: quem estuda >5h x <2h
filtro_Estudo_alto = df["study_hours_per_day"] > 5
filtro_estudo_baixo = df["study_hours_per_day"] < 2

grupo_estudo_alto = df[filtro_Estudo_alto]["exam_score"]
grupo_estudo_baixo = df[filtro_estudo_baixo]["exam_score"]

print("Média notas (estuda > 5h):", grupo_estudo_alto.mean())
print("Média notas (estuda < 2h):", grupo_estudo_baixo.mean())
```

Média notas (estuda > 5h): 90.79419354838709


Média notas (estuda < 2h): 45.56390977443609

- O tempo gasto em redes sociais afeta o desempenho dos alunos?

```
In [8]: # Redes sociais: distribuição geral (Histograma)
# x="social_media_hours"


sns.histplot(data=df, x="social_media_hours")
plt.title("Distribuição de tempo em redes sociais")
plt.show()
```

Distribuição de tempo em redes sociais





```
In [9]: #Avaliando notas médias
#por diferentes intervalos (bins) de periodos gastos em redes sociais
# ["0-2h", "2h-4h", "4h-6h", "6h+"]


df["social_media_bin"] = pd.cut(
    df["social_media_hours"],
    bins=[0, 2, 4, 6],
    labels=["0-2h", "2h-4h", "4h-6h"]
)
#Gráfico de caixa
sns.boxplot(x="social_media_bin", y="exam_score", data=df)
plt.title("Notas por tempo em redes sociais")
plt.show()
```



- Alunos mais saudáveis têm melhores desempenhos?

```
In [10]: #Frequência de exercícios físicos
for col in ["exercise_frequency", "mental_health_rating", "diet_quality"]:
    sns.boxplot(x=col, y="exam_score", data=df)
    plt.show()
```





- Há diferença nas notas entre homens e mulheres?

```
In [11]: #Estatística por gênero (média e desvio padrão)
df.groupby(["gender"])["exam_score"].agg(["mean", "std"])
```

```
Out[11]:      mean      std
gender
Female  69.741372  16.899351
Male    69.368344  17.150875
Other   70.647619  13.755890
```

```
In [19]: #Avaliar distribuição de gênero
df["gender"].value_counts(normalize=True)
```

```
Out[19]: gender
Female    0.481
Male      0.477
Other     0.042
Name: proportion, dtype: float64
```